# Analiza danych biomechanicznych pingwinów (Palmer Penguins)

## 1. Informacja na temat wybranych danych

Zbiór danych **Palmer Penguins** zyskał dużą popularność jako nowoczesna, doskonała alternatywa dla klasycznego zbioru Iris. Został on zebrany i udostępniony przez dr Kristen Gorman oraz stację badawczą *Palmer Station, Antarktyda* (w ramach Long Term Ecological Research Network).

Zbiór pozwala na szczegółową analizę relacji cech fizycznych pingwinów uwzględniając podział na płeć i gatunek. Na drodze wstępnego sprawdzenia, usunięto z niego wiersze z brakami danych (metodą `dropna`), aby uniknąć błędów agregacji.

**Opis poszczególnych badanych cech (zmiennych):**

- **Gatunek (species)** - zmienna grupująca przypisująca pingwina do jednego z trzech gatunków: *Adelie, Chinstrap, Gentoo*.
- **Płeć (sex)** - zmienna grupująca: *male* (samiec), *female* (samica). Zmienna ta jest wprost powiązana z naturalnym dymorfizmem płciowym badanej grupy.
- **Wyspa (island)** - Biscoe, Dream, Torgersen (miejsce na archipelagu Palmera, gdzie badano dany osobniki).
- **Masa ciała (body_mass_g)** - waga danego osobnika obserwowana w gramach.
- **Wymiary fizyczne** – zmienne podane w milimetrach:
  - `flipper_length_mm` - długość płetwy.
  - `bill_length_mm` - długość dzioba.
  - `bill_depth_mm` - głębokość (grubość) dzioba.

## 2. Wykorzystane narzędzia

Do wczytania, odpowiedniego wyczyszczenia danych z braków, oraz ich grupowego przetworzenia wykorzystano środowisko **Python** oraz dedykowane, popularne moduły deweloperskie i analityczne:

- **`pandas`** – fundamentalny pakiet pozwalający wczytać zbiór jako `DataFrame`, a także dokonać agregacji korzystając z potężnej metody okienkowej `groupby()` (wyliczenie wariantów w grupie) ze wsparciem statystycznego `describe()`.
- **`matplotlib.pyplot` oraz `seaborn`** – połączone bilbioteki do precyzyjnej wizualizacji. Wykorzystano m.in. zautomatyzowane metody nakładania na siebie różnokolorowych grup dla typowych statystycznych dystrybucji z wykorzystaniem obiektów: histogramu (`histplot`), wykresu dyspersyjnego (`scatterplot`) oraz klasycznego pudełko-wąsy (`boxplot`).

## 3. Zmienne grupujące i wskaźniki sumaryczne (Analiza Porównawcza)

Podstawą tego badania było potraktowanie masy ciała (`body_mass_g`) jako zmiennej zależnej, natomiast dla **analizy porównawczej** uwzględniono tu koniunkcję dwóch kluczowych zmiennych grupujących (cechach jakościowych): **płci (sex)** oraz **gatunku (species)**.

Poniższa tabela dowodzi uśrednionych statystyk oraz wartości dyspersyjnych przygotowanych wprost z wykonanego programu.

**Tabela: Statystyki sumaryczne dla Masy Ciała w gramach.**

| Gatunek (species) | Płeć (sex) | Liczebność całkowita | Średnia masa (mean) | Mediana (median) | Odch. stand. (std) |
|---|---|---|---|---|---|
| Adelie | Female | 73 | 3368.84 | 3400.0 | 269.38 |
| Adelie | Male | 73 | 4043.49 | 4000.0 | 346.81 |
| Chinstrap | Female | 34 | 3527.21 | 3550.0 | 285.33 |
| Chinstrap | Male | 34 | 3938.97 | 3950.0 | 362.14 |
| Gentoo | Female | 58 | 4679.74 | 4700.0 | 281.58 |
| Gentoo | Male | 61 | 5484.84 | 5500.0 | 313.16 |

## 4. Wyniki wizualne: Najważniejsze wykresy

Przedstawiono wizualizacje ilustrujące i sprawdzające kluczowe rozkłady wg zmiennych grupujących. Poniższe wykresy dostarczają nie tylko statystycznego dowodu na powiązania płci, ale również pomagają zweryfikować badawczą klasyfikację różnych gatunków.

### A. Rozkład masy ciała z badaniem płci

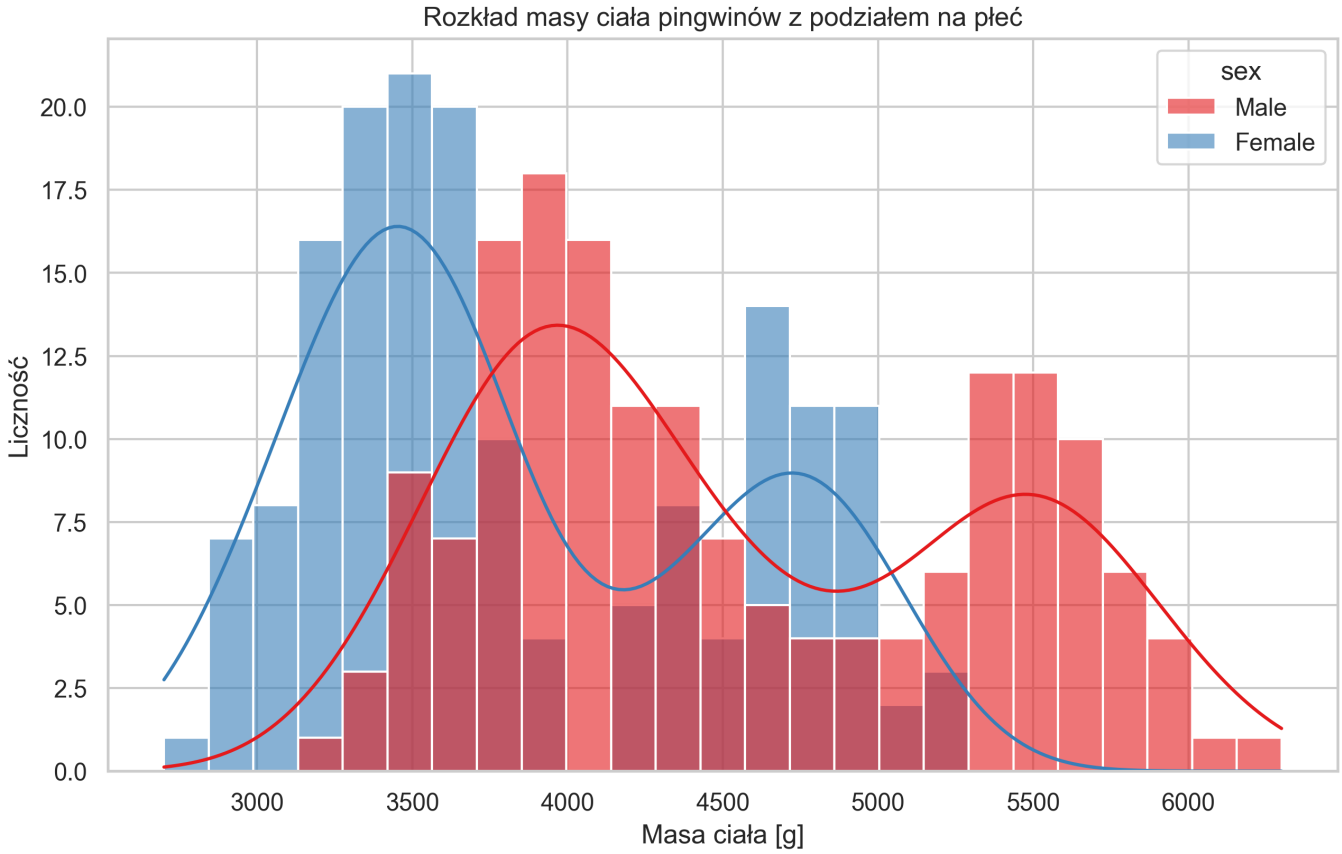


## B. Różnice fizjologiczne względem grup

Wykres typu "Boxplot" badający przedziały (kwartyle) dla długości płetwy potwierdza zbieżne różnice dla wielkości grup pingwinów, będąc dodatkowo skorelowanym z masą ciała (patrz: Gentoo).

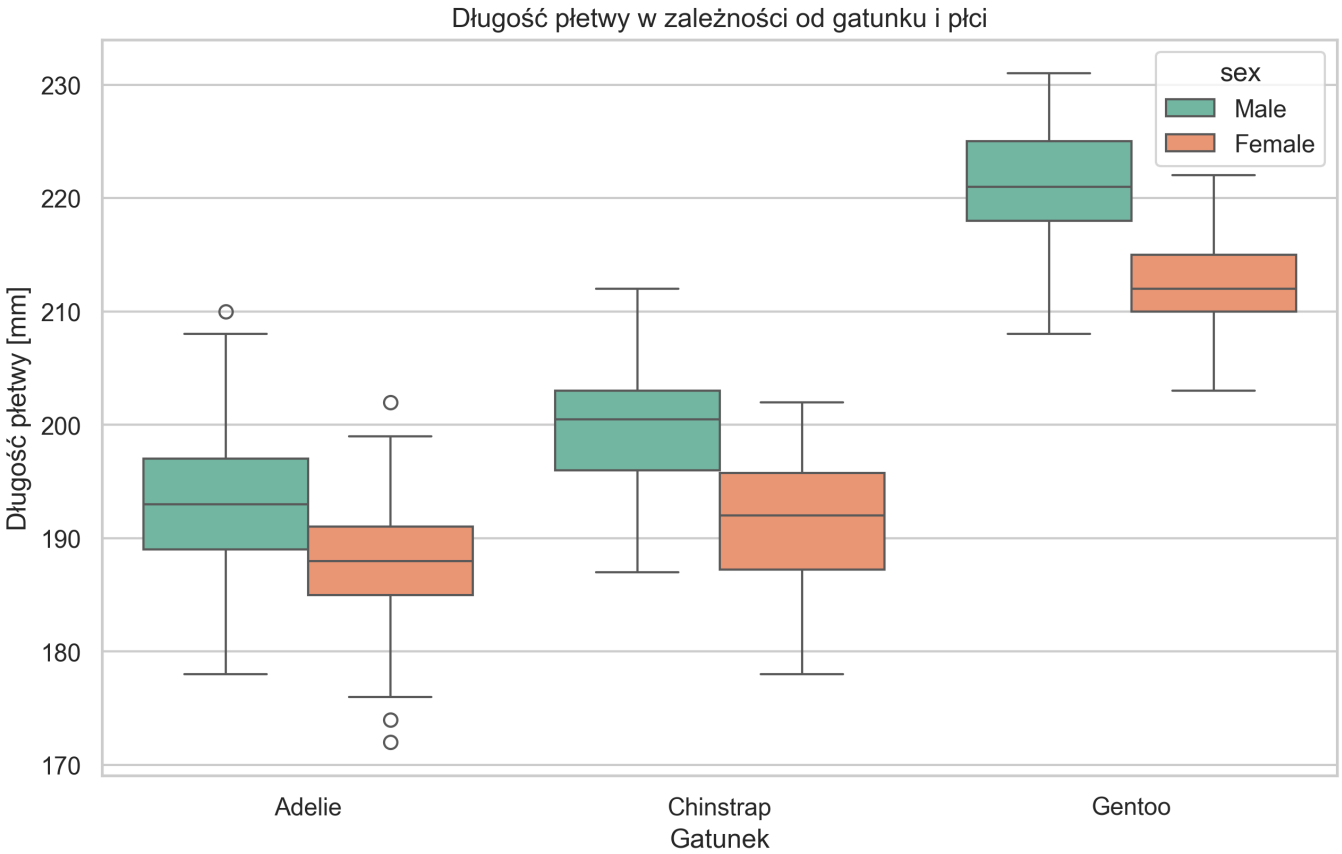

### C. Analiza wymiarów dzioba dla poszczególnych gatunków

Korelacja dwóch numerycznych zmiennych z zastosowanym rzutowaniem na klaster grupy.

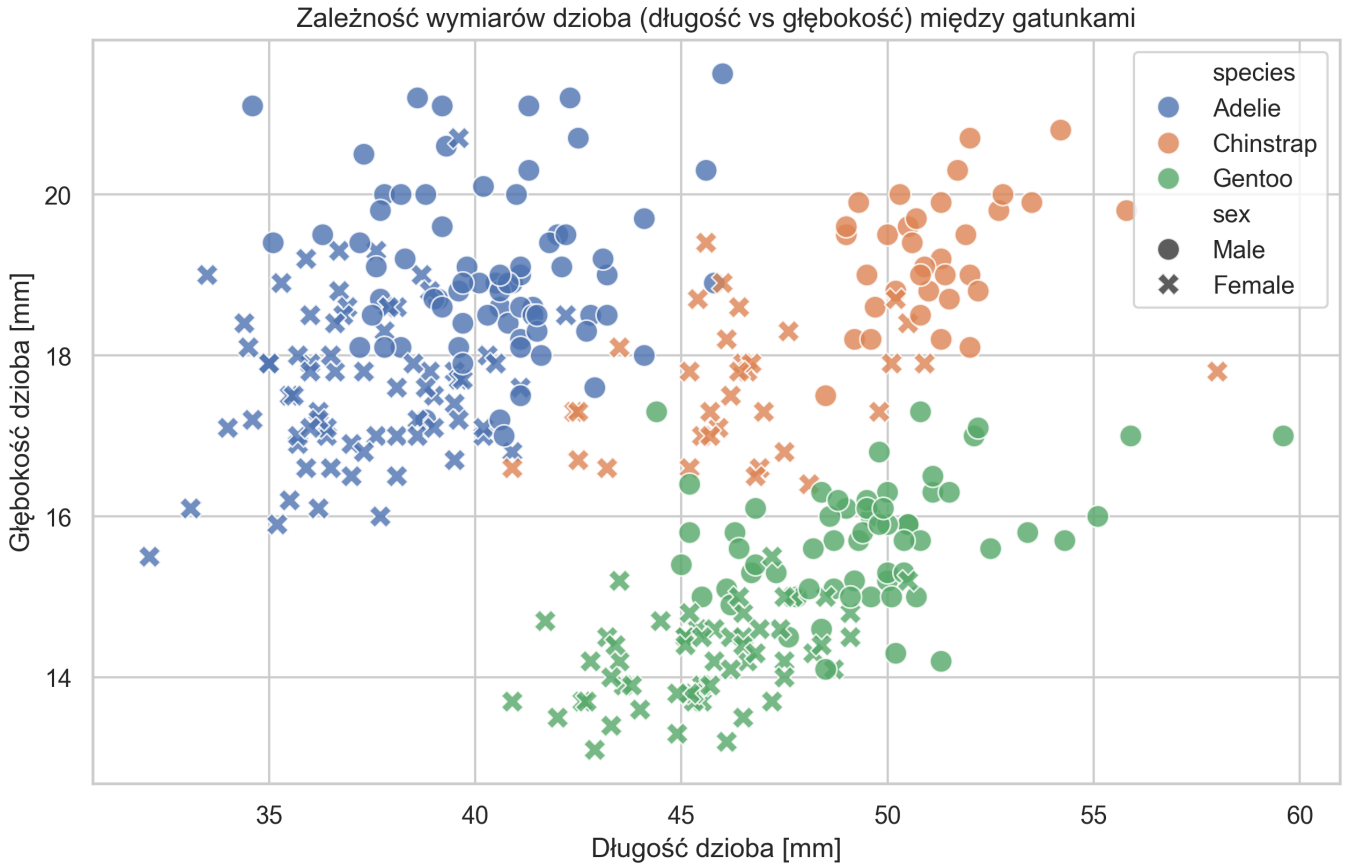


## 5. Interpretacja poszczególnych wyników - Wnioski

Analiza podziału biomechanicznego połączonych i zgrupowanych czynnikowo pingwinów pozwala sprecyzować bardzo wyraźne i łatwe do oceny konkluzje naukowe:

1. **Widoczny dymalizm płciowy**: Statystyki uzyskane dla populacji bezsprzecznie udowadniają, iż niezależnie od gatunku, samce z tych samych grup (*males*) są znacząco cięższe ("różnica płci" wynosi średnio koło 500g-800g przewagi na korzyść samca) oraz cechują się wyraźnie dłuższymi płetwami w porównaniu z samicami. Co więcej, histogram dowodzi, że jest to zjawisko zbiegające do pewnych rozkładów normalnych spiętrzonych dla badanych grup osobno.

2. **Cechy gatunku nadpisywane przez płeć**: Widać drastyczną przewagę wielkości fizjologicznych osobnika **Gentoo**. Nawet samice z grupy Gentoo są na ogół zauważalnie cięższe, a ich płetwy są dłuższe (mediana to ok. 210~215 mm) niż wskaźniki najcięższych w stawce i dobrze zbudowanych samców z grup Adelie i Chinstrap.

3. **Bardzo silne zgrupowania klastrowe wymiarów dzioba (Scatter Plot)**: Korelacja wymiarów dzioba jest świetnym predykatem i bardzo trafną zmienną klasyfikującą konkretny przypadek biologiczny. Jak wynika z wykresu rozrzutu, pomiar zaledwie dwóch uwarunkowań - długości oraz głębokości (grubości) dzioba - powoduje tworzenie się trzech idealnie wyszarpanych naturalnych wysepek (klastrów), które bezpośrednio odpowiadają konkretnemu rodzajowi pingwina. Taki dowód jednoznacznie wspiera tworzenie algorytmów sztucznej inteligencji, w których na podstawie cech dzioba bezbłędnie klasyfikuje się te odrębne na archipelagu grupy bez konieczności badania genetycznego zwierzęcia.