Metody planowania i analizy eksperymentów - Analiza opisowa wybranych danych (zadanie domowe nr 1)

1. Informacja na temat wybranych danych

Zbiór danych **Palmer Penguins** jest często wykorzystywany jako alternatywa dla klasycznego zbioru Iris. Dane zostały zebrane i udostępnione przez dr Kristen Gorman oraz stację badawczą Palmer Station, Antarktyda (w ramach Long Term Ecological Research Network).

Zbiór ten pozwala przeanalizować zależności między cechami fizycznymi pingwinów z uwzględnieniem podziału na ich płeć i gatunek. Dane zostały wstępnie oczyszczone, usunięto z nich wiersze z brakującymi rekordami (metodą `dropna`), aby uniknąć błędów agregacji.

Opis poszczególnych cech (zmiennych):

- **Gatunek (species)** - zmienna grupująca przypisująca pingwina do jednego z trzech gatunków: *Adelie, Chinstrap, Gentoo*.
- **Płeć (sex)** - zmienna grupująca: *male* (samiec), *female* (samica). Zmienna ta jest wprost powiązana z naturalnym dymorfizmem płciowym badanej grupy.
- **Wyspa (island)** - *Biscoe, Dream, Torgersen* (miejsce na archipelagu Palmera, gdzie badano danego osobnika).
- **Masa ciała (body_mass_g)** - waga danego osobnika obserwowana w gramach.
- **Wymiary fizyczne** - zmienne podane w milimetrach:
    - `flipper_length_mm` - długość płetwy.
    - `bill_length_mm` - długość dzioba.
    - `bill_depth_mm` - głębokość (grubość) dzioba.

2. Wykorzystane narzędzia

Do wczytania, odpowiedniego wyczyszczenia z braków danych w niektórych zmiennych, oraz ich grupowego przetworzenia wykorzystano szeroko pojęte środowisko **Python** oraz dedykowane, popularne pakiety deweloperskie (biblioteki) przeznaczone do tego rodzaju analizy:

- **`pandas`** - fundamentalny pakiet pozwalający wczytać zbiór jako `DataFrame`, a także dokonać agregacji korzystając z metody okienkowej `groupby()` (obliczanie statystyk dla każdej grupy) ze wsparciem statystycznego `describe()`.
- **`matplotlib.pyplot`** oraz **`seaborn`** - są to biblioteki służące do wizualizacji danych. Wykorzystano między innymi wizualizację rozkładów danych dla różnych grup z wykorzystaniem obiektów: histogramu (`histplot`), wykresu dyspersyjnego (`scatterplot`) oraz klasycznego wykresu pudełko-wąsy (`boxplot`).

3. Wskaźniki sumaryczne

Podstawą tego badania było potraktowanie masy ciała (`body_mass_g`) jako zmiennej zależnej, natomiast dla analizy porównawczej uwzględniono tu koniunkcję dwóch kluczowych zmiennych grupujących (cech jakościowych): **płci (sex)** oraz **gatunku (species)**.

Tabela: Statystyki sumaryczne dla **masy ciała (body_mass_g)** w gramach.

Gatunek (species)	Płeć (sex)	Liczebność całkowita	Średnia masa (mean)	Mediana (median)	Odch. stand. (std)
Adelie	Female	73	3368.84	3400.0	269.38
Adelie	Male	73	4043.49	4000.0	346.81
Chinstrap	Female	34	3527.21	3550.0	285.33
Chinstrap	Male	34	3938.97	3950.0	362.14
Gentoo	Female	58	4679.74	4700.0	281.58
Gentoo	Male	61	5484.84	5500.0	313.16

4. Wyniki wizualne (wykresy)

Przedstawiono wizualizacje przedstawiające rozkłady danych wg zmiennych grupujących. Poniższe wykresy pozwalają nie tylko zaobserwować zależności, ale również pomagają zweryfikować badawczą klasyfikację różnych gatunków.

A. Rozkład masy ciała z badaniem płci

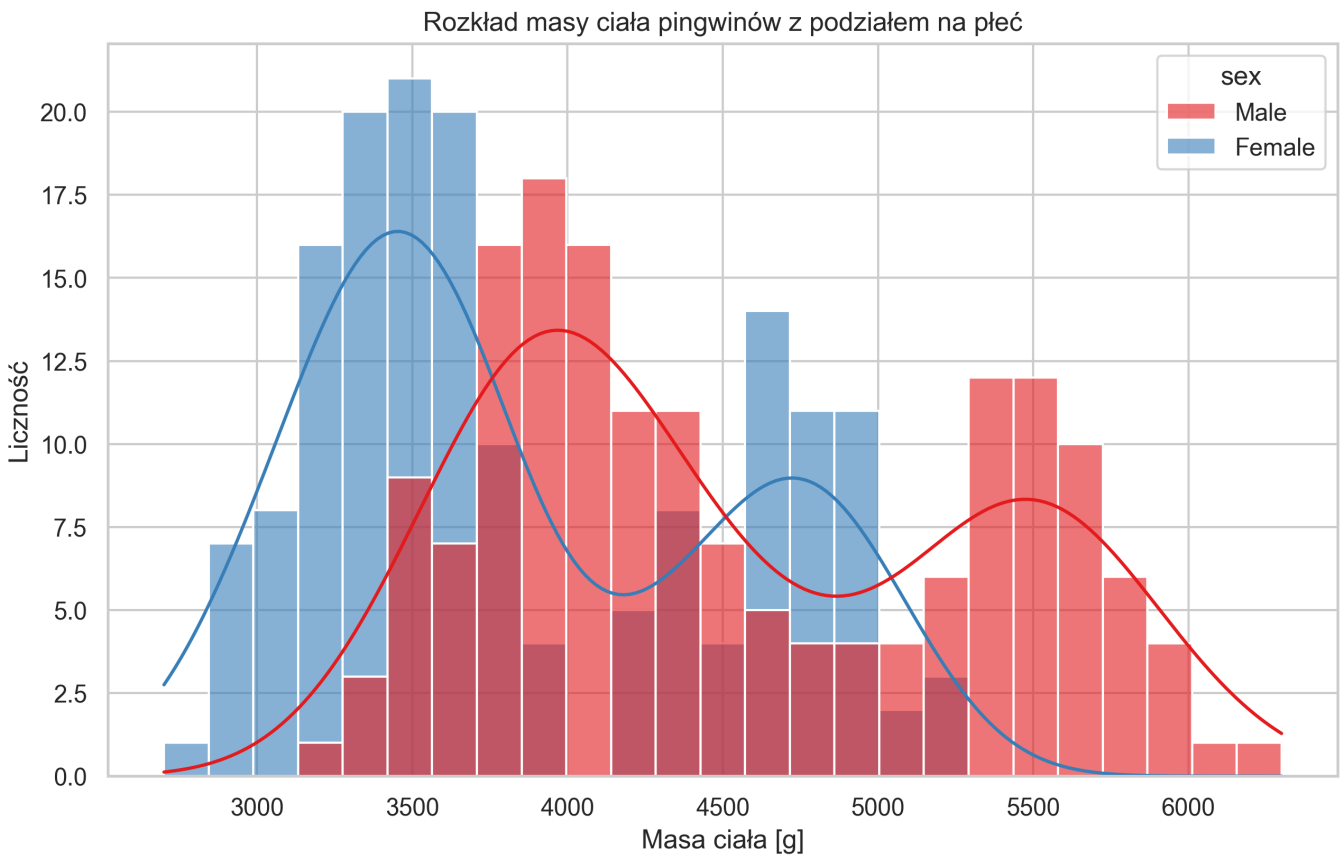

B. Różnice fizjologiczne względem grup

Wykres typu "Boxplot", przedstawiający kwartyle dla długości płetwy, potwierdza wyraźne różnice między grupami pingwinów (co jest również skorelowane z masą ciała). Szczególnie dobrze widoczne jest to dla gatunku Gentoo, którego nawet samice - na ogół lżejsze z mniejszymi płetwami - są istotnie większe i cięższe od innych gatunków.

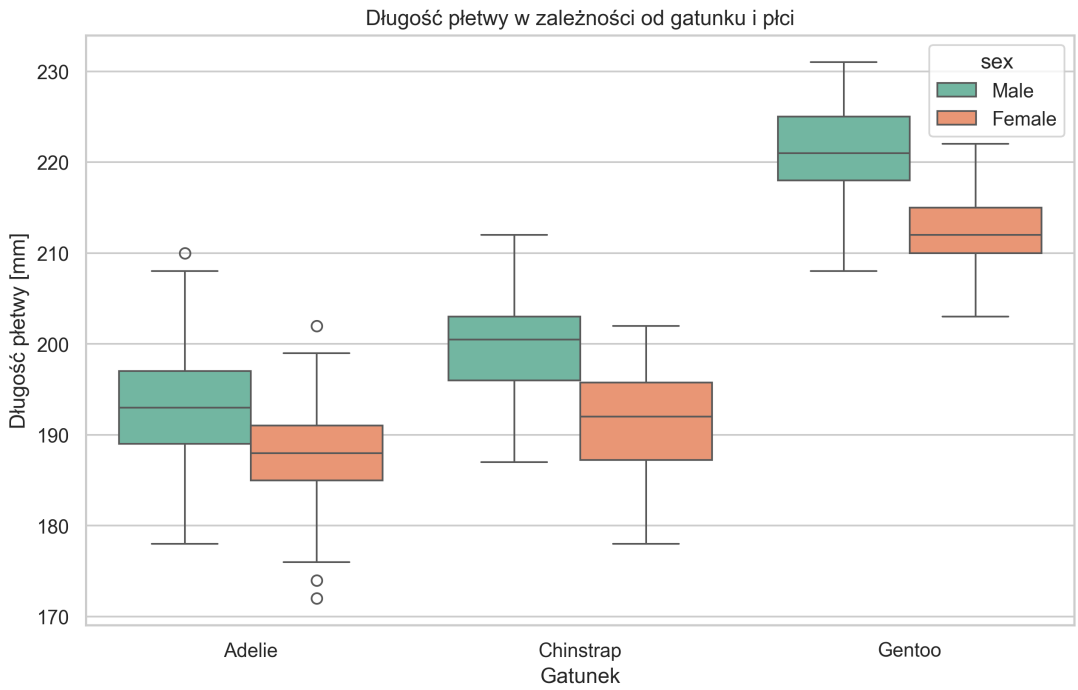

C. Analiza wymiarów dzioba dla poszczególnych gatunków

Wykres punktowy (scatter plot) pokazujący korelację między długością a głębokością dzioba. Widać tu wyraźne zgrupowania (klastry) odpowiadające poszczególnym gatunkom, co sugeruje, że te cechy są dobrymi predyktorami do klasyfikacji pingwinów.

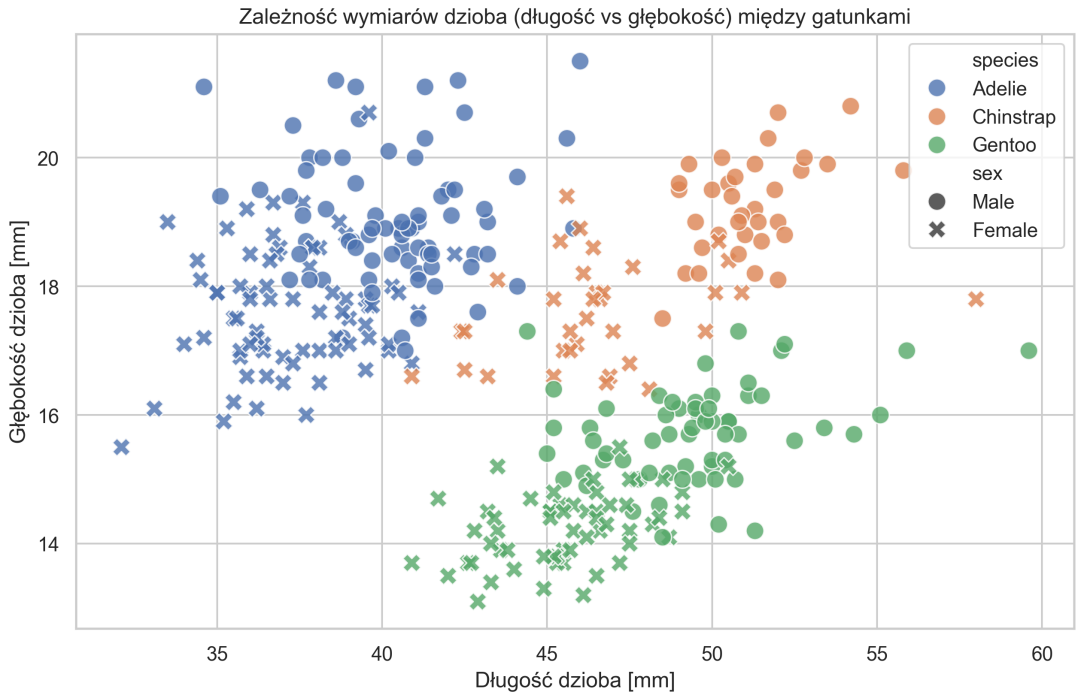

5. Interpretacja poszczególnych wyników - wnioski

Analiza powyższych danych dotyczących pingwinów pozwala na wyciągnięcie kilku kluczowych wniosków:

1. **Widoczny dymorfizm płciowy**: Statystyki jasno pokazują, że samce (niezależnie od tego, o jakim gatunku mówimy) są wyraźnie większe i cięższe od samic. Przeciętny samiec jest o około 500-800 gramów cięższy i ma zauważalnie dłuższą płetwę. Na histogramie widać wyraźne przesunięcie rozkładów masy dla obu płci.

2. **Cechy gatunku nadpisywane przez płeć**: Gatunek **Gentoo** wyraźnie wyróżnia się pod względem wielkości. Nawet samice z grupy Gentoo są na ogół zauważalnie cięższe, a ich płetwy są dłuższe (mediana to ok. 210~215 mm) niż wskaźniki najcięższych w stawce i dobrze zbudowanych samców z grup **Adelie** i **Chinstrap**.

3. **Bardzo silne zgrupowania klastrowe wymiarów dzioba (Scatter Plot)**: Korelacja wymiarów dzioba jest dobrą cechą do rozróżnienia i bardzo trafną zmienną do klasyfikacji gatunków. Jak wynika z wykresu rozrzutu, pomiar zaledwie dwóch cech - długości oraz głębokości dzioba - pozwala na niemal całkowitą separację gatunków. Tworzą one trzy wyraźne klastry, co sugeruje, że parametry te są wystarczające do budowy skutecznego modelu klasyfikacyjnego bez konieczności wykonywania kosztownych badań genetycznych.

Autor:
Aleksander Stepaniuk 272644