Metody planowania i analizy eksperymentów - Wnioskowanie statystyczne (zadanie domowe nr 2)

1. Informacja na temat wybranych danych

Poniższy raport jest kontynuacją zadania pierwszego, wykorzystano ten sam zbiór danych **Palmer Penguins** (pingwiny z rejonu Palmer Station, Antarktyda), ale tym razem nacisk położono na wnioskowanie statystyczne, a nie tylko analizę opisową.

Opis poszczególnych cech (zmiennych):

- **Gatunek (species)** - zmienna grupująca przypisująca pingwina do jednego z trzech gatunków: *Adelie, Chinstrap, Gentoo*.
- **Płeć (sex)** - zmienna grupująca: *male* (samiec), *female* (samica). Zmienna ta jest wprost powiązana z naturalnym dymorfizmem płciowym badanej grupy.
- **Wyspa (island)** - *Biscoe, Dream, Torgersen* (miejsce na archipelagu Palmera, gdzie badano danego osobnika).
- **Masa ciała (body_mass_g)** - waga danego osobnika obserwowana w gramach.
- **Wymiary fizyczne** - zmienne podane w milimetrach (flipper_length_mm, bill_length_mm, bill_depth_mm).

W analizie skoncentrowano się na:

- zmiennej ilościowej **body_mass_g** (masa ciała w gramach),
- zmiennej grupującej **sex** (Female, Male),
- porównaniu dwóch *niezależnych* populacji: samice vs samce.

Dane oczyszczono z braków dla zmiennych **sex** i **body_mass_g** (korzystając z `dropna`). Po czyszczeniu otrzymano:

- Female: **165** obserwacji,
- Male: **168** obserwacji.

2. Wykorzystane narzędzia

Do wczytania, odpowiedniego wyczyszczenia z braków danych w niektórych zmiennych, oraz ich grupowego przetworzenia wykorzystano szeroko pojęte środowisko **Python** oraz dedykowane, popularne pakiety deweloperskie (biblioteki) przeznaczone do tego rodzaju analizy:

- **`pandas`**: `read_csv`, `dropna`, `groupby`, `agg` - wczytanie danych i estymacja punktowa.
- **`numpy`**: `mean`, `var`, `sqrt` - obliczenia numeryczne pomocnicze.
- **`scipy.stats`**:
  - `sem` oraz `t.ppf` - konstrukcja 95% przedziałów ufności,
  - `ttest_ind(..., equal_var=False)` - test t-Welcha dla dwóch niezależnych prób.
- **`seaborn` + `matplotlib`**: `histplot`, `boxplot` - wizualizacja rozkładów.

3. Model statystyczny i założenia

3.1. Model statystyczny

W analizie stosuje się model **dwóch niezależnych populacji** o następujących właściwościach:

- **Populacja 1 (Female):** $X_1 \sim F_1(\mu_1, \sigma_1^2)$
- **Populacja 2 (Male):** $X_2 \sim F_2(\mu_2, \sigma_2^2)$

gdzie:

- μ_1, μ_2 – **średnie masy ciała w populacjach** (nieznane),
- σ_1^2, σ_2^2 – **wariancje populacji** (nieznane).

Uzasadnienie wyboru modelu:

- populacje (samice i samce) są niezależne i reprezentują różne grupy biologiczne,
- średnie i wariancje populacji nie są znane i muszą być estymowane z próby,
- liczebności prób (Female: 165, Male: 168) są wystarczające do zastosowania testów parametrycznych.

3.2. Sprawdzenie założenia normalności

Normalność rozkładu zmiennej `body_mass_g` w obu grupach badano za pomocą **testu Shapiro-Wilka**.

Hipotezy testu:

- H_0: zmienna ma rozkład normalny,
- H_1: zmienna nie ma rozkładu normalnego.

Wyniki:

Grupa	n	Statystyka	p-value	Decyzja (α=0.05)
Female	165	0.9193	< 0.00000001	Odrzucamy H_0
Male	168	0.9250	< 0.00000001	Odrzucamy H_0

Interpretacja: W obu grupach wartości p-value są znacznie mniejsze niż α = 0.05, co prowadzi do odrzucenia hipotezy o normalności rozkładu masy ciała. Oznacza to, że rozkład `body_mass_g` **nie ma rozkładu normalnego** ani w grupie samic, ani w grupie samców.

Implikacje dla analizy: Pomimo naruszenia założenia normalności, test t-Welcha jest stosunkowo odporny na odchylenia od normalności dla większych prób (Central Limit Theorem). Ze względu na liczebności próby (n > 100 w obu grupach) oraz symetryczne rozkłady (co widać na histogramach), test t-Welcha pozostaje uzasadniony, choć można byłoby również zastosować test nieparametryczny (Mann-Whitney'a).

4. Wyniki

Wymagane metody wnioskowania zastosowano dla zmiennej **body_mass_g**.

4.1. Estymacja punktowa

Tabela: statystyki punktowe masy ciała w grupach płci.

Płeć	Liczebność	Średnia [g]	Mediana [g]	Odch. stand. [g]
Female	165	3862.27	3650.0	666.17
Male	168	4545.68	4300.0	787.63

- średnia ogółem: **4207.06 g**,
- estymator różnicy średnich (Male - Female): **683.41 g**.

4.2. Estymacja przedziałowa (95% CI)

Przedziały konstruowano na podstawie rozkładu t-Studenta.

$$CI_{95\%}(\mu) = \bar{x} \pm t_{0.975,\,n-1} \cdot \frac{s}{\sqrt{n}}$$

oraz dla różnicy średnich (wariant Welcha):

$$CI_{95\%}(\mu_{Male} - \mu_{Female}) = \hat{\Delta} \pm t_{0.975,\,\nu} \cdot SE(\hat{\Delta})$$

Parametr	Estymator	CI95 dół	CI95 góra
Średnia masa ciała (ogółem)	4207.06	4120.26	4293.86
Średnia masa ciała (Female)	3862.27	3759.87	3964.67
Średnia masa ciała (Male)	4545.68	4425.71	4665.65
Różnica średnich (Male - Female)	683.41	526.25	840.58

Ważna obserwacja: przedział dla różnicy średnich nie zawiera 0.

4.3. Weryfikacja hipotezy statystycznej

Przeprowadzono **dwustronny test t-Welcha** dla dwóch niezależnych populacji.

- H_0: $\mu_{Male} = \mu_{Female}$,
- H_1: $\mu_{Male} \neq \mu_{Female}$,
- poziom istotności: $\alpha = 0.05$.

Wyniki testu:

- statystyka: $t = 8.5545$,
- stopnie swobody (Welch): $df = 323.90$,
- p-value: **< 0.00000001**.

Ponieważ $p < \alpha$, **odrzucamy** H_0.

5. Wizualizacja rozkładów

Histogram potwierdza przesunięcie rozkładu masy ciała w prawo dla grupy Male, a boxplot pokazuje wyższą medianę i kwartyle w tej grupie.

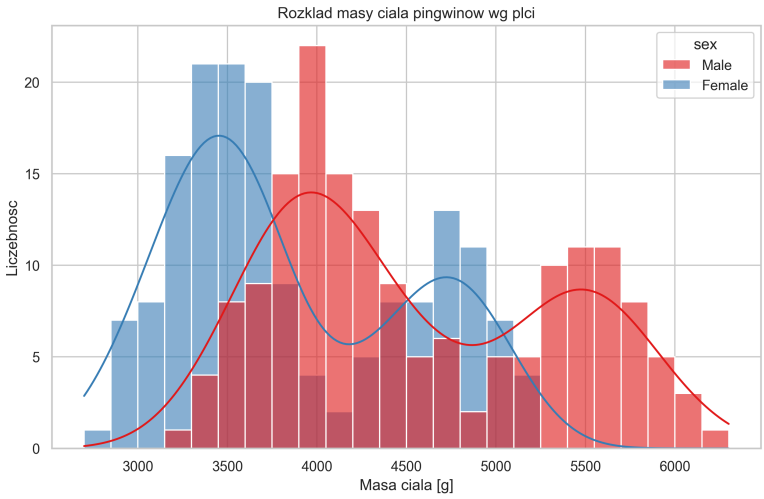

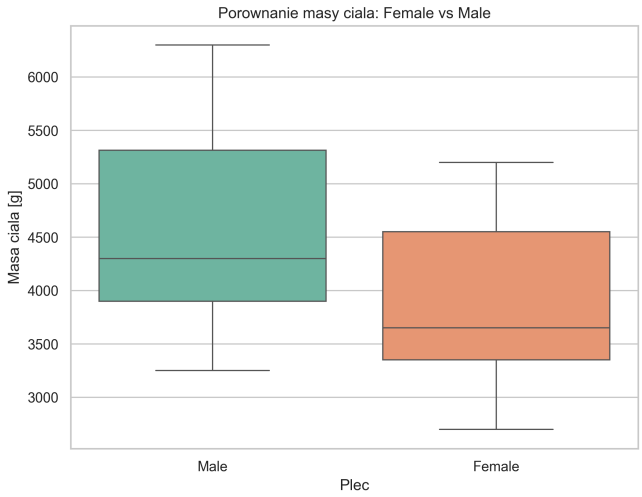

6. Interpretacja wyników i wnioski

1. **Wniosek o średnich**: samce są średnio cięższe od samic o około **683 g**, co jest różnicą dużą z punktu widzenia praktycznego.
2. **Wniosek przedziałowy**: z 95% pewnością rzeczywista różnica średnich (Male - Female) mieści się w zakresie **od 526.25 g do 840.58 g**.
3. **Wniosek testowy**: bardzo małe p-value prowadzi do odrzucenia hipotezy o równości średnich, czyli różnica nie jest przypadkowa statystycznie.
4. **Spójność z biologią**: wyniki są zgodne z oczekiwanym dymorfizmem płciowym u pingwinów i potwierdzają obserwacje z zadania 1 na poziomie inferencyjnym.

Autor:
Aleksander Stepaniuk 272644