Wykorzystanie algorytmów genetycznych do optymalizacji przejazdu pojazdu w symulowanych środowiskach deterministycznych

Autor: Aleksander Stepaniuk

Promotor: dr hab. inż. Michał Przewoźniczek, prof. uczelni

Motywacja i uzasadnienie tematu

Potrzeba praktyczna

Planowanie optymalnej trajektorii jest istotne dla celów praktycznych, na przykład w zakresie planowania trajektorii dla statków kosmicznych lub autonomicznych robotów [1, 2].

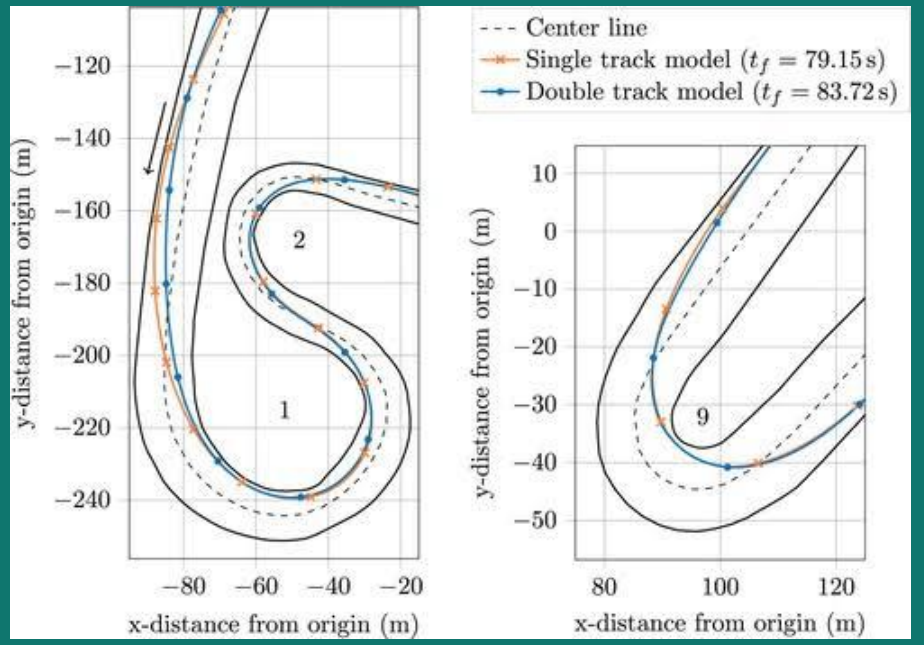
Alternatywa do dotychczasowych podejść

W symulacjach sterowania pojazdem często stosuje się uczenie ze wzmocnieniem, oparte na obserwacji środowiska [3]. Algorytmy genetyczne są zupełnie innym podejściem do problemu. Pozwalają optymalizować istniejący już przejazd lub poszukiwać zróżnicowanych trajektorii, a także ulepszać je w kolejnych iteracjach.

Interesujący problem badawczy

W tak zdefiniowanym problemie, geny mają znaczenie chronologiczne. Przeszłe geny wpływają bezpośrednio na przyszłe, ale nie odwrotnie. Jakie zależności między nimi można wykorzystać?

Przykład:



[1] R. Chai i in., IEEE Trans. Cybern. 50(4), 2020
[2] Z. Chen, H.-T. Zhang, IEEE Trans. Cybern. 47(8), 2017
[3] TMRL: github.com/trackmania-rl/tmrl

Problem badawczy

Jak znaleźć sekwencję akcji, która doprowadzi pojazd do mety w jak najkrótszym czasie w symulacji deterministycznej?

Genotyp

Przykładowo:
30s * 60 akcji/s = 1800 genów
Każdy gen ∈ {0...15}: 4 bity
[gaz, hamulec, lewo, prawo]

Symulator

Deterministyczny dwuwymiarowy silnik fizyczny, wykonujący odpowiednie obliczenia.

Fitness

Postęp gradientowy:
0,0 na starcie;
1,0 na mecie.

Wstępne pytania badawcze

Pytanie 1

Czy uwzględnienie chronologicznej struktury genotypu poprawia wyniki względem standardowego GA? (Linkage Learning)

Pytanie 2

Czy krzyżowanie osobników o podobnym stanie pojazdu (pozycja, prędkość, kierunek) jest skuteczniejsze od zwykłego krzyżowania?

Pytanie 3

Czy wiele populacji wyspecjalizowanych w pewnych odcinkach trasy, łączonych w jedno rozwiązanie, jest skuteczniejsze od standardowego GA przy tym samym budżecie ewaluacji?

Cel i zakres pracy

Cel

Zaproponować nowy optymalizator oparty na idei algorytmu genetycznego, który skuteczniej niż standardowy GA optymalizuje trajektorię pojazdu w deterministycznym środowisku symulowanym.

Zakres pracy

1. Przegląd literatury o optymalizacji trajektorii i algorytmach ewolucyjnych
2. Sformułowanie problemu i własny deterministyczny symulator 2D
3. Zbiór instancji testowych o różnym poziomie złożoności - losowo generowane trasy
4. Implementacja optymalizatorów konkurencyjnych: standardowy GA, P3[4], GOMEA[5]
5. Autorskie mechanizmy i optymalizator (krzyżowanie, selekcja, wiele populacji)
6. Eksperymenty obliczeniowe, analiza wyników oraz podsumowanie

[4] B. W. Goldman, W. F. Punch, Parameter-less Population Pyramid, GECCO 2014; A. E. Eiben, J. E. Smith, Introduction to Evolutionary Computing
[5] D. Thierens, P. A. N. Bosman, *Optimal Mixing Evolutionary Algorithms*, GECCO 2011.

Narzędzia, metodyki i techniki

C++: symulator

Prosty, deterministyczny model przejazdu pojazdu po torze. Powinien być szybki i pozwalać na wiele szybkich ewaluacji.

C++: optymalizatory

Standardowy GA, P3[4], GOMEA[5], oraz autorski optymalizator.

Python: analiza

Wykresy, zestawienia wyników, porównanie optymalizatorów (ew. wizualizacja przejazdów symulatora).

Ocena osobnika: gradient postępu (przykład dla 6 checkpointów)



[4] B. W. Goldman, W. F. Punch, Parameter-less Population Pyramid, GECCO 2014; A. E. Eiben, J. E. Smith, Introduction to Evolutionary Computing
[5] D. Thierens, P. A. N. Bosman, *Optimal Mixing Evolutionary Algorithms*, GECCO 2011.

Oczekiwane rezultaty



Wkład dla nauki

Nowy optymalizator oparty na GA dla optymalizacji trajektorii pojazdu w środowiskach deterministycznych.

Wiedza o zależnościach między genami o charakterze chronologicznym.



Wynik badań

Porównanie wyników przy takim samym budżecie obliczeniowym lub takim samym czasie ewaluacji autorskiego optymalizatora względem SOTA.



Wynik praktyczny

Narzędzie do poprawy istniejącego przejazdu (linii wyścigowej).

Potencjalne wykorzystanie przy innych projektach wymagających optymalizacji trajektorii.

Dziękuję za uwagę. Zapraszam do zadawania pytań.